参赛计划书（简化版）

> **大赛名称：** 第十二届全国大学生统计建模大赛
> **大赛主题：** "服务国家战略 创新统计赋能"
> **论文题目：** 《数字经济对区域碳排放强度的影响研究——基于面板回归与机器学习的实证分析》

一、选题背景与研究意义

1.1 现实背景

中国提出"双碳"目标（2030碳达峰、2060碳中和），同时数字经济快速发展，已成为经济增长新引擎。

核心问题： 数字经济能否有效降低碳排放？哪些数字经济因素对减碳最重要？

1.2 研究意义

- **理论意义**：探讨数字经济和碳排放之间的关系，丰富相关文献
- **方法意义**：将传统回归分析与机器学习相结合，用SHAP进行可解释性分析
- **实践意义**：为政策制定提供数据支撑

1.3 契合大赛主题

- **"服务国家战略"**：对接"双碳"目标 + 数字中国战略
- **"创新统计赋能"**：统计回归 + 机器学习预测 + SHAP可解释性

1.4 创新点

1. **方法结合**：将面板回归（分析因果）和机器学习（预测+SHAP解释）相结合
2. **指标构建**：用熵权法构建数字经济综合指数（4维度、12指标）
3. **政策参考**：基于SHAP特征重要性排序，提出针对性政策建议

二、研究问题与假设

2.1 三个核心问题

编号	问题	方法
RQ1	数字经济是否显著降低了碳排放强度？	固定效应回归
RQ2	数字经济通过什么机制影响碳排放？	中介效应分析
RQ3	哪些数字经济子维度对碳减排贡献最大？	机器学习 + SHAP

2.2 研究假设

编号	假设内容
H1	数字经济发展显著降低区域碳排放强度
H2	数字经济通过**产业结构优化**降低碳排放强度
H3	数字经济通过**绿色技术创新**降低碳排放强度

三、研究方法

3.1 总体思路

```
数据采集与清洗
      ↓
构建数字经济综合指数（熵权法）
      ↓
  ┌──────────┬──────────┐
  ↓                     ↓
统计回归分析          机器学习预测
（因果推断）          （预测+解释）
  │                     │
  ↓                     ↓
① 固定效应回归        ① 随机森林
② 中介效应分析        ② XGBoost
③ 稳健性检验          ③ SHAP可解释分析
  │                     │
  └──────────┬──────────┘
             ↓
      结论与政策建议
```

3.2 统计回归部分

模型一：基准回归（双向固定效应）

$$CO2_{it} = \alpha_0 + \alpha_1 DE_{it} + \gamma X_{it} + \mu_i + \delta_t + \varepsilon_{it}$$

- $CO2_{it}$：碳排放强度（CO2/GDP）
- DE_{it}：数字经济综合指数
- X_{it}：控制变量
- μ_i：省份固定效应，δ_t：时间固定效应

模型二：中介效应（三步法）

```
路径一：数字经济 → 产业结构优化 → 碳排放强度↓
路径二：数字经济 → 绿色技术创新 → 碳排放强度↓
```

使用逐步回归法（Baron & Kenny三步法）+ Sobel检验

3.3 机器学习部分

模型选择

模型	特点	调参方法
随机森林	稳健、不易过拟合	5折交叉验证
XGBoost	预测精度高	5折交叉验证 + GridSearch

评价指标

指标	说明
R^2	解释方差比例，越大越好
RMSE	均方根误差，越小越好
MAE	平均绝对误差，越小越好

SHAP可解释性分析

用SHAP值分析每个特征对碳排放预测的贡献方向和大小。

需要做3张SHAP图：

图表	作用
SHAP蜂群图	展示所有特征的重要性排序
SHAP柱状图	直观对比各因素影响大小
SHAP依赖图	展示某个特征的非线性影响

3.4 稳健性检验（4项）

序号	方法	操作
1	替换因变量	用人均碳排放替代碳排放强度
2	替换自变量构建方法	用PCA替代熵权法构建指数
3	缩尾处理	连续变量1%和99%缩尾
4	排除直辖市	剔除北京、天津、上海、重庆

四、数据来源与变量

4.1 数据范围

- **空间范围**：30个省份（除港澳台及西藏）
- **时间范围**：2011-2023年

4.2 变量设计

类型	变量	说明	数据来源
因变量	碳排放强度	CO2/GDP	CEADs
核心自变量	数字经济指数	熵权法构建	多源整合
控制变量	人均GDP	ln处理	国家统计局
控制变量	产业结构	第二产业/GDP	国家统计局
控制变量	城镇化率	城镇人口比例	统计年鉴
控制变量	能源结构	煤炭占比	能源统计年鉴
中介变量	产业结构高级化	三产/二产	国家统计局
中介变量	绿色技术创新	ln(绿色专利数)	CNIPA

4.3 数字经济指数构建

维度	指标	来源
数字基础设施	互联网普及率、移动电话普及率、光缆长度	统计年鉴
数字产业发展	电信业务总量、IT服务收入、软件业务收入	工信部
数字金融发展	覆盖广度、使用深度、数字化程度	北大数金指数
数字创新能力	数字专利数、R&D人员密度、技术市场成交额	CNIPA等

五、论文大纲

```
标题：数字经济对区域碳排放强度的影响研究
        ——基于面板回归与机器学习的实证分析

摘要（300字）

1. 引言（1000字）
   1.1 背景
   1.2 研究意义与创新点

2. 文献综述（1500字）
   2.1 数字经济与碳排放相关研究
   2.2 机器学习在碳排放研究中的应用
```

```
3. 研究设计（2000字）
   3.1 基准回归模型
   3.2 中介效应模型
   3.3 机器学习模型与SHAP框架
   3.4 变量说明与数据来源

4. 实证分析（5000字）
   4.1 描述性统计
   4.2 基准回归结果
   4.3 中介效应分析
   4.4 机器学习预测与SHAP分析
       - 模型对比
       - SHAP特征重要性
       - SHAP依赖图分析

5. 稳健性检验与异质性分析（1500字）
   5.1 稳健性检验（4项）
   5.2 东/中/西部分组回归

6. 结论与政策建议（1000字）

参考文献
                    正文合计 ≈ 12,000字
```

六、图表清单（约10张）

编号	内容	工具
图1	技术路线图	Draw.io
图2	碳排放趋势图	Python
图3	ML模型预测对比图	Python
图4	SHAP蜂群图	Python shap
图5	SHAP柱状图	Python shap
图6	SHAP依赖图	Python shap
表1	描述性统计	—
表2	基准回归结果	Stata/Python
表3	中介效应结果	Stata/Python
表4	模型预测精度对比	Python
表5	稳健性检验汇总	Stata/Python

七、工具与分工

7.1 软件

任务	工具
数据清洗	Python (pandas)
统计回归	Stata 或 Python (statsmodels)
机器学习	Python (sklearn, xgboost)
SHAP分析	Python (shap)

7.2 核心代码参考

```
import pandas as pd
import numpy as np
from sklearn.ensemble import RandomForestRegressor
from xgboost import XGBRegressor
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error
import shap
import matplotlib.pyplot as plt

# 1. 读取数据
df = pd.read_csv('panel_data.csv')

features = [
    '互联网普及率', '移动电话普及率', '光缆长度',
    '电信业务总量', 'IT服务收入', '软件业务收入',
    '金融覆盖广度', '金融使用深度', '金融数字化程度',
    '数字专利数', 'RD人员密度', '技术市场成交额',
    'ln人均GDP', '产业结构', '城镇化率', '能源结构'
]
target = '碳排放强度'

# 2. 划分训练集/测试集
train = df[df['年份'] <= 2020]
test  = df[df['年份'] >= 2021]
X_train, y_train = train[features], train[target]
X_test,  y_test  = test[features],  test[target]

# 3. 训练模型
xgb = XGBRegressor(n_estimators=200, max_depth=5, learning_rate=0.05, random_state=42)
xgb.fit(X_train, y_train)

rf = RandomForestRegressor(n_estimators=200, random_state=42)
rf.fit(X_train, y_train)
```

```python
# 4. 模型对比
for name, model in [('XGBoost', xgb), ('RandomForest', rf)]:
    y_pred = model.predict(X_test)
    print(f"{name}: R²={r2_score(y_test, y_pred):.4f}, "
          f"RMSE={np.sqrt(mean_squared_error(y_test, y_pred)):.4f}")

# 5. SHAP分析
explainer = shap.TreeExplainer(xgb)
shap_values = explainer.shap_values(X_test)

shap.summary_plot(shap_values, X_test, feature_names=features)
shap.summary_plot(shap_values, X_test, feature_names=features, plot_type='bar')
```

八、时间安排（约35天）

阶段	时间	任务	产出
一：数据准备	3/30 - 4/7	文献阅读、数据采集清洗	面板数据CSV
二：统计回归	4/8 - 4/14	熵权法建指数、基准回归、中介效应	回归结果
三：ML建模	4/15 - 4/19	训练模型、SHAP分析	ML结果和图
四：论文写作	4/20 - 4/27	撰写初稿、整理图表	论文初稿
五：修改完善	4/28 - 5/3	查重、修改、准备提交材料	终稿

7.3 团队分工

角色	职责
队员A	统计回归（Stata/Python）
队员B	数据处理 + ML建模 + SHAP
队员C	论文撰写 + 材料整理

九、提交材料清单

- [ ] 报名表
- [ ] 承诺书
- [ ] AI工具使用情况表
- [ ] 论文正文（PDF）
- [ ] 查重报告
- [ ] 数据和代码包